Repaso ayudantía

Jocelyn Tapia Stefanoni

Universidad Técnica Federico Santa María

Ramas de la Estadística

La Estadística se divide en dos áreas:

- **Estadística Descriptiva:** se emplea como una primera aproximación a los datos. Utiliza tablas y gráficos para resumir la información disponible.
- **Estadística Inferencial:** va un poco más allá. A partir de los datos desarrolla mecanismos de decisión parar determinar si los datos sustentan o no una hipótesis. Permite hacer predicciones.

Estadística Descriptiva

- Los **estadísticos** son funciones de los datos de una muestra:

$$f(X_1, ..., X_n)$$

- **gráficos**: histogramas, gráficos de caja
- **tablas**: de frecuencia, contingencia, etc.

Estadísticos de Localización Central

- **Media empírica o promedio**:

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

- **Mediana**: Si se tiene una muestra $X_1, ..., X_n$, se ordenan los datos de menor a mayor: $X_{(1)}, ...X_{(n)}$. La mediana es la observación que queda en el medio.

$$Med(X_1, ..., X_n) = \begin{cases} X_{(\frac{n+1}{2})}, & \text{si } n \text{ es impar} \\ \frac{X_{(n/2)} + X_{(n/2+1)}}{2}, & \text{si } n \text{ es par} \end{cases}$$

Estadísticos de Localización Central

- Suponiendo que se tienen 13 datos (caso de n impar):

$$X_{(1)}, ..., \underbrace{X_{(7)}}_{\text{mediana}}, ..., X_{(13)}$$

- Suponiendo que se tienen 12 datos (caso de n par):

$$X_{(1)}, ..., \underbrace{X_{(6)}, X_{(7)}}_{\text{mediana}=\frac{X_{(6)}+X_{(7)}}{2}}, ..., X_{(12)}$$

Estadísticos de Localización

- Un percentil es una medida estadística que indica la posición de un dato dentro de un conjunto de observaciones, dividiendo los datos en 100 partes iguales.
- Los percentiles más empleados son: P_{25}, $P_{50} = Mediana$, P_{75} y se conocen como ***cuartiles*** ya que dividen a los datos en 4 partes (se suelen nombrar q_1, q_2 y q_3).
- También existen los **quintiles** y **deciles**, según se dividan a los datos en 5 o 10 partes.

Estadísticos de dispersión

- El ***rango intercuartílico***: se define como:

$$RIQ(X_1, ..., X_n) = q_3 - q_1$$

- La ***varianza muestral o empírica*** se define como:

$$Var(X_1, ..., X_n) = \frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n-1}$$

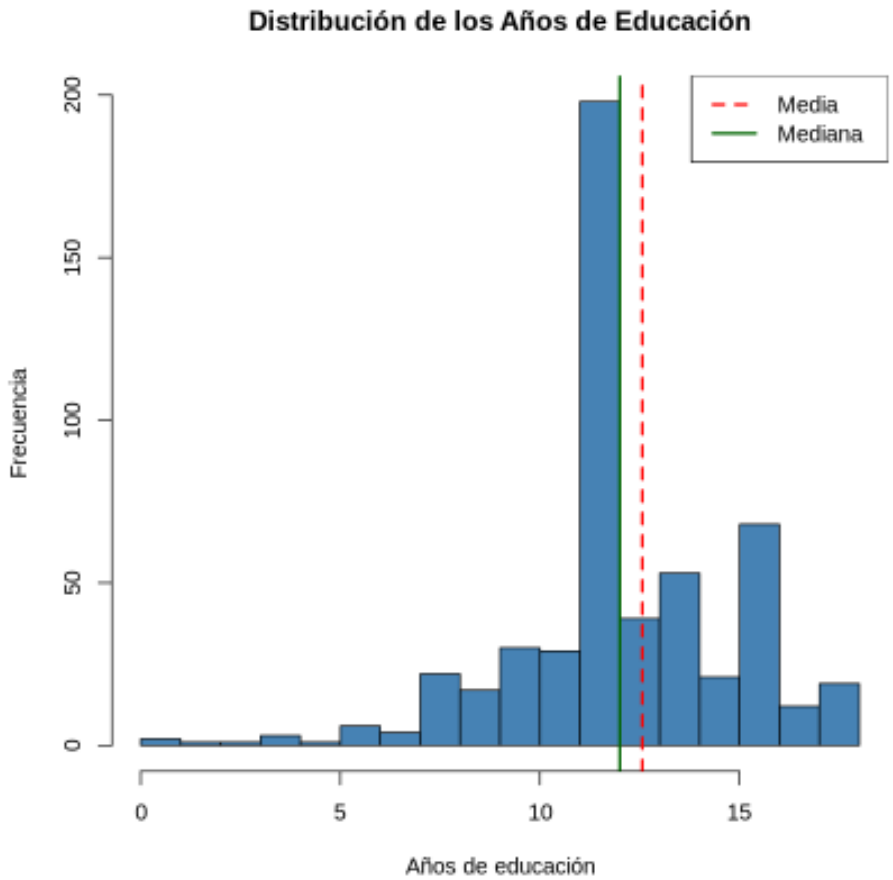
Estadísticos de dispersión

- La ***desviación estándar muestral o empírico*** es la raíz cuadrada de la varianza, es decir:

$$S(X_1, ..., X_n) = \sqrt{\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n-1}}$$

Histograma

El histograma resume los datos dentro de algunos rangos y se cuenta el número de observaciones dentro de cada rango.



Colab

Gráfico de caja - Boxplot



Gráfico de caja - Boxplot

- *Línea en medio de la caja*: Med (mediana).
- *Límite superior de la caja*: q_3 (tercer cuartil).
- *Límite inferior de la caja*: q_1 (primer cuartil).
- notar que el largo de la caja representa el RIQ (rango intercuartilico).
- *Bigote superior*: es el mínimo entre $q_3 + 1{,}5RIQ$ y el máximo de los datos (X_n).
- *Bigote inferior*: es el máximo entre $q_1 - 1{,}5RIQ$ y el mínimo de los datos (X_1).
- *Puntos fuera de los bigotes*: Todos los puntos que exceden los bigotes se grafican. Son puntos extremos (atípicos).